

机器学习之监督学习


# 线性判别分析(LDA)

倪冰冰


上海交通大学

# 监督学习

- 给定一组数据，我们知道正确的输出结果应该是什么样子，并且知道在输入和输出之间有着一个特定的关系  $f(x)$ 。
- 分类 vs 回归




分类(Classification)



回归(Regression)

# 线性分类模型


线性分类器



思路一：用超平面（线）将不同类样本分开

# 线性分类器

- 线性分类器



分类器参数( $w, b$ )

$$y = f(x) = w^T x + b$$

# 线性分类器实例

输入图像特征 $x$



$32 \times 32 \times 3$

图像分类器

$$f(x) = w^T x + b$$

$3072 \times 1$

$3072 \times 1$

$1 \times 1$

输出预测值

$$f(x) = 0.6$$

正例

$$\begin{pmatrix} x \\ w \end{pmatrix} = \begin{pmatrix} 0.1 \\ 0.2 \\ 0.1 \end{pmatrix} \cdot \begin{pmatrix} 1.0 \\ 3.0 \\ 1.0 \end{pmatrix}$$


$$+ \begin{pmatrix} b \end{pmatrix} = 0.9$$

反例

$$\begin{pmatrix} x \\ w \end{pmatrix} = \begin{pmatrix} 0.1 \\ -0.2 \\ 0.2 \end{pmatrix} \cdot \begin{pmatrix} 1.0 \\ 3.0 \\ 1.0 \end{pmatrix}$$

$$+ \begin{pmatrix} b \end{pmatrix} = -0.2$$

阈值操作









"1"

"0"

# 如何训练模型

● 模型学习：如何从数据中训练得到最佳参数 $w, b$

## 1.训练数据准备

	$x_1$	$y_1 = 1$
	$x_2$	$y_2 = 1$
	$x_3$	$y_3 = 1$
	$x_4$	$y_4 = -1$
	$x_5$	$y_5 = -1$
	$x_6$	$y_6 = -1$

## 2.定义损失函数


$$-y_i(w^T x_i + b)$$
$$\left\{ \begin{array}{l} f(x) < 0 \\ f(x) > 0 \end{array} \right.$$

若标签为正，预测为正

若标签为正，预测为负

损失函数：
$$L(\{x_i\}; w, b) = - \sum_i y_i (w^T x_i + b)$$


## 3.最小化损失函数



$$\frac{\partial L}{\partial b} = - \sum_i y_i$$
$$\frac{\partial L}{\partial w} = - \sum_i y_i x_i^T$$

梯度下降

# 线性分类模型



思路二：映射到新的空间，新的空间里“同类近，异类远”

Linear Discriminant Analysis 线性判别分析

# Linear Discriminant Analysis


- 假设两类问题(Binary Classification)

$u_1$ : 表示第一类样本的均值向量

$$u_1 = \frac{1}{N_1} \sum_{i \in C_1} x_i$$

$u_2$ : 表示第二类样本的均值向量

$$u_2 = \frac{1}{N_2} \sum_{i \in C_2} x_i$$



数据集

$$\{(x_i, y_i)\}_{i=1}^m$$

- 表示第一类  $C_1$
- ★ 表示第二类  $C_2$
- × 第一类中心  $u_1$
- × 第二类中心  $u_2$




# Linear Discriminant Analysis

- 假设两类问题(Binary Classification)

类间距离  $d = |\mathbf{w}^T \mathbf{u}_1 - \mathbf{w}^T \mathbf{u}_2|$

距离平方

$$\begin{aligned} d^2 &= (\mathbf{w}^T \mathbf{u}_1 - \mathbf{w}^T \mathbf{u}_2)(\mathbf{u}_1^T \mathbf{w} - \mathbf{u}_2^T \mathbf{w}) \\ &= \mathbf{w}^T (\mathbf{u}_1 - \mathbf{u}_2)(\mathbf{u}_1 - \mathbf{u}_2)^T \mathbf{w} \end{aligned}$$



数据集

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^m$$

- 表示第一类  $C_1$
- ★ 表示第二类  $C_2$
- × 第一类中心  $\mathbf{u}_1$
- × 第二类中心  $\mathbf{u}_2$

目标1: 通过一个映射 $\mathbf{w}$ , 将映射到 $\mathbf{w}$ 轴上的两中心点 $\mathbf{w}^T \mathbf{u}_1$ 与 $\mathbf{w}^T \mathbf{u}_2$ 之间距离最大

# Linear Discriminant Analysis

- 假设两类问题(Binary Classification)


类内距离  $d_1 = \sum_{i \in C_1} |\mathbf{w}^T \mathbf{x}_i - \mathbf{w}^T \mathbf{u}_1|$

距离“平方”

$$d_1^2 = \sum_{i \in C_1} (\mathbf{w}^T \mathbf{x}_i - \mathbf{w}^T \mathbf{u}_1)(\mathbf{x}_i^T \mathbf{w} - \mathbf{u}_1^T \mathbf{w})^T$$

$$= \mathbf{w}^T \sum_{i \in C_1} (\mathbf{x}_i - \mathbf{u}_1)(\mathbf{x}_i - \mathbf{u}_1)^T \mathbf{w}$$

$D \times D$  维矩阵  $\Sigma_1$  第一类样本协方差矩阵



数据集

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^m$$

● 表示第一类  $C_1$

★ 表示第二类  $C_2$

× 第一类中心  $\mathbf{u}_1$

× 第二类中心  $\mathbf{u}_2$

$$d_1^2 + d_2^2 = \mathbf{w}^T \Sigma_1 \mathbf{w} + \mathbf{w}^T \Sigma_2 \mathbf{w}$$

目标2: 通过一个映射 $\mathbf{w}$ , 每个类内数据 $\mathbf{w}^T \mathbf{x}_i$ 与其均值 $\mathbf{w}^T \mathbf{u}_1$ 之间距离最小

# Linear Discriminant Analysis

- 假设两类问题(Binary Classification)

类内距离越小，同时类间聚类越大

$$d_w = \mathbf{w}^T \Sigma_1 \mathbf{w} + \mathbf{w}^T \Sigma_2 \mathbf{w} \quad \downarrow \quad d_b = \mathbf{w}^T (\mathbf{u}_1 - \mathbf{u}_2) (\mathbf{u}_1 - \mathbf{u}_2)^T \mathbf{w} \quad \uparrow$$

$$\max \frac{d_b}{d_w}$$

终极目标：如何同时满足目标1和目标2

# Linear Discriminant Analysis

- 假设两类问题(Binary Classification)

记:  $d_w = \mathbf{w}^T \Sigma_1 \mathbf{w} + \mathbf{w}^T \Sigma_2 \mathbf{w} = \mathbf{w}^T (\Sigma_1 + \Sigma_2) \mathbf{w} = \mathbf{w}^T S_w \mathbf{w}$

其中:  $S_w = \Sigma_1 + \Sigma_2$  称为类内散射矩阵

$$d_b = \mathbf{w}^T (\mathbf{u}_1 - \mathbf{u}_2) (\mathbf{u}_1 - \mathbf{u}_2)^T \mathbf{w} = \mathbf{w}^T S_b \mathbf{w}$$

其中:  $S_b = (\mathbf{u}_1 - \mathbf{u}_2) (\mathbf{u}_1 - \mathbf{u}_2)^T$  称为类间散射矩阵

$$\max \frac{d_b}{d_w} \implies \max \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$$

# Linear Discriminant Analysis

- LDA的目标: 最大化广义瑞利商  $J$  (generalized Rayleigh quotient)

$$\text{单值} \longleftarrow J(\mathbf{w}) = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}} \longrightarrow \mathbf{w} \text{ 成倍缩放不影响 } J \text{ 值}$$

仅考虑方向

求偏导数, 设为0, 求解 $\mathbf{w}$

$$\begin{aligned} \frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} &= \frac{(w^T S_b w)' w^T S_w w - w^T S_b w (w^T S_w w)'}{(w^T S_w w)^2} \\ &= \frac{2(w^T S_w w) S_b w - 2(w^T S_b w) S_w w}{(w^T S_w w)^2} \end{aligned} \quad \Rightarrow \quad \begin{aligned} \frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} = 0 &\Rightarrow (w^T S_w w) S_b w - (w^T S_b w) S_w w = 0 \\ &\Rightarrow S_b w - J S_w w = 0 \\ &\Rightarrow S_b w = J S_w w \\ &\Rightarrow \boxed{S_w^{-1} S_b w = J w} \end{aligned}$$

变成特征值分解问题!

# Linear Discriminant Analysis

- LDA的解

$$S_W^{-1} S_B \mathbf{w} = J \mathbf{w}$$

特征值分解矩阵  $S_W^{-1} S_B$   $D \times D$  方阵

最优的  $\mathbf{w}$  即为最大的特征值所对应的那个特征向量!

$$A \mathbf{e} = \lambda \mathbf{e}$$

Why?

$$S_W^{-1} S_B \mathbf{w}_m = J_m \mathbf{w}_m$$

$$J(\mathbf{w}_m) = \frac{\mathbf{w}_m^T S_B \mathbf{w}_m}{\mathbf{w}_m^T S_W \mathbf{w}_m} = \frac{\mathbf{w}_m^T (S_W J_m \mathbf{w}_m)}{\mathbf{w}_m^T S_W \mathbf{w}_m}$$

$$= \frac{J_m \mathbf{w}_m^T S_W \mathbf{w}_m}{\mathbf{w}_m^T S_W \mathbf{w}_m} = J_m \longrightarrow \text{最大化!}$$

$$S_W^{-1} S_B = [e_1 \quad \cdots \quad e_D] \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & 0 & \lambda_D \end{bmatrix} \begin{bmatrix} e_1^T \\ \vdots \\ e_D^T \end{bmatrix}$$

$$\text{单值} \longleftarrow J(\mathbf{w}) = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}$$

# Linear Discriminant Analysis

- 使用LDA进行分类
  - 获得最优的映射方向w
  - 将所有原始数据均映射至一维 (1D)

数据集  $\{(\mathbf{x}_i, l_i)\}_{i=1:N}$       $y_1 = \mathbf{w}^T \mathbf{x}_1$       $y_2 = \mathbf{w}^T \mathbf{x}_2$       $y_3 = \mathbf{w}^T \mathbf{x}_3$      .....      $y_N = \mathbf{w}^T \mathbf{x}_N$




$\{(y_i, l_i)\}_{i=1:N}$

使用K近邻分类器

● A类样本

● B类样本

● 待分类样本



# Linear Discriminant Analysis

- 若原数据 $\mathbf{x}$ 维度较高，映射到一维（1D）恐怕信息损失较多，不利于分类
- 那就保留更多的维度！

$$S_w^{-1} S_B \mathbf{w} = J \mathbf{w}$$

不仅保留最大特征值对应的特征向量 $\mathbf{w}_m$ ，还可以保留“次大”的向量 $\mathbf{w}_{m-1}, \mathbf{w}_{m-2}$ 等

假设保留2D维度

数据集  $\{(\mathbf{x}_i, l_i)\}_{i=1:N}$



$\{(\mathbf{y}_i, l_i)\}_{i=1:N}$

现在 $\mathbf{y}_i$ 是一个低维度向量

$$\begin{array}{llll} y_1^1 = \mathbf{w}_m^T \mathbf{x}_1 & y_1^2 = \mathbf{w}_{m-1}^T \mathbf{x}_1 & \dots & y_1^N = \mathbf{w}_m^T \mathbf{x}_N \\ y_2^1 = \mathbf{w}_m^T \mathbf{x}_2 & y_2^2 = \mathbf{w}_{m-1}^T \mathbf{x}_2 & \dots & y_2^N = \mathbf{w}_m^T \mathbf{x}_N \\ \vdots & \vdots & \ddots & \vdots \\ y_N^1 = \mathbf{w}_m^T \mathbf{x}_N & y_N^2 = \mathbf{w}_{m-1}^T \mathbf{x}_N & \dots & y_N^N = \mathbf{w}_m^T \mathbf{x}_N \end{array}$$

貌似：最多可以保留到原来的维度！

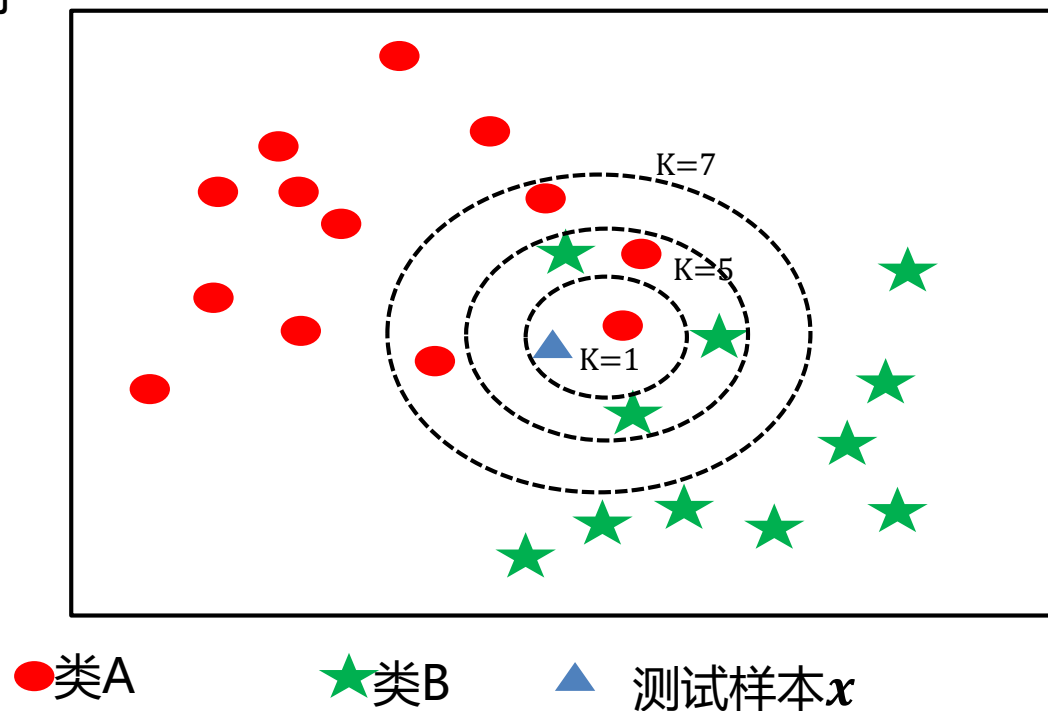


# Linear Discriminant Analysis

- 假设降到2维后的K近邻分类
  - 根据距离度量公式（如欧式距离），寻找它的k个近邻
  - 根据它的k个近邻中每个类别出现的频率，确定它的类别

## 本例中

1. 当 $K=1$ 时,  $x$ 的近邻样本中类A出现1次, 类B出现0次, 因此预测为类A
2. 当 $K=5$ 时,  $x$ 的近邻样本中类A出现2次, 类B出现3次, 因此预测为类B
3. 当 $K=7$ 呢?



# 多类问题LDA

- 与两类问题LDA的异同

	两类问题	多类问题
类内中心	$\mathbf{u}_1 \quad \mathbf{u}_2$	$\mathbf{u}_1 \quad \mathbf{u}_2 \quad \mathbf{u}_3 \quad \mathbf{u}_4 \quad \cdots$
类间散射矩阵	$S_b = (\mathbf{u}_1 - \mathbf{u}_2)(\mathbf{u}_1 - \mathbf{u}_2)^T$	?
类内散射矩阵	$S_w = \sum_{i \in C_1} (\mathbf{x}_i - \mathbf{u}_1)(\mathbf{x}_i - \mathbf{u}_1)^T + \sum_{i \in C_2} (\mathbf{x}_i - \mathbf{u}_2)(\mathbf{x}_i - \mathbf{u}_2)^T$	$S_w = \sum_{j=1:M} \sum_{i \in C_j} (\mathbf{x}_i - \mathbf{u}_j)(\mathbf{x}_i - \mathbf{u}_j)^T$

# 多类问题LDA

- 多类问题LDA

定义全局散度矩阵

$$S_T = \sum_{i=1}^N (\mathbf{x}_i - \mathbf{u})(\mathbf{x}_i - \mathbf{u})^T \quad \mathbf{u} \text{ 为所有数据样本的中心}$$

$S_T$ 是什么?

$$\begin{aligned} S_T &= \sum_{i=1}^N (\mathbf{x}_i - \mathbf{u})(\mathbf{x}_i - \mathbf{u})^T = \sum_{j=1}^M \sum_{i \in C_j}^{N_j} (\mathbf{x}_i - \mathbf{u}_j + \mathbf{u}_j - \mathbf{u})(\mathbf{x}_i - \mathbf{u}_j + \mathbf{u}_j - \mathbf{u})^T \\ &= \sum_{j=1}^M \sum_{i \in C_j}^{N_j} (\mathbf{x}_i - \mathbf{u}_j)(\mathbf{x}_i - \mathbf{u}_j)^T + \sum_{j=1}^M \sum_{i \in C_j}^{N_j} (\mathbf{u}_j - \mathbf{u})(\mathbf{u}_j - \mathbf{u})^T + 2 \sum_{j=1}^M \sum_{i \in C_j}^{N_j} (\mathbf{x}_i - \mathbf{u}_j)(\mathbf{u}_j - \mathbf{u})^T \\ &= \underbrace{\sum_{j=1}^M S_w^j}_{S_w} + \underbrace{\sum_{j=1}^M N_j (\mathbf{u}_j - \mathbf{u})(\mathbf{u}_j - \mathbf{u})^T}_{S_b} + 0 \end{aligned} \quad \Rightarrow \quad S_T = S_w + S_b$$

# 多类问题LDA

- 与两类问题同样的解法

$$S_w^{-1} S_b \mathbf{w} = \lambda \mathbf{w}$$

特征值分解!

若类的个数是 $M$ ， $\mathbf{w}$ 顶多有 $M - 1$ 个有意义!

因为  $S_b = \sum_{j=1}^M N_j (\mathbf{u}_j - \mathbf{u})(\mathbf{u}_j - \mathbf{u})^T$  秩顶多 $M - 1$ ，所以 $S_w S_b$ 顶多有 $M - 1$ 个大于0的特征值!

所以顶多能降到 $M - 1$ 维!

所以对于两类问题，LDA顶多可以降到1维!

# LDA降维实战

用scikit-learn进行LDA降维

## 【对scikit-learn中LDA类概述】

在scikit-learn中，LDA类是sklearn.discriminant\_analysis.LinearDiscriminantAnalysis。

参数总结：

- solver：求LDA超平面特征矩阵使用的方法；
- shrinkage：正则化参数，默认是None；
- priors：类别权重，一般用于分类，降维时不考虑；
- n\_components：进行LDA降维时降到的维数。

# LDA降维实战

用scikit-learn进行LDA降维

## 【生成三维数据特征】

---


```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
%matplotlib inline
from sklearn.datasets.samples_generator import make_classification
X, y = make_classification(n_samples=1000, n_features=3, n_redundant=0, n_classes=3,
                          n_informative=2, n_clusters_per_class=1, class_sep=0.5, random_state=10)
fig = plt.figure()
ax = Axes3D(fig, rect=[0, 0, 1, 1], elev=30, azimuth=20)
plt.scatter(X[:, 0], X[:, 1], X[:, 2], marker='o', c=y)
```

---

# LDA降维实战

用scikit-learn进行LDA降维

【三维数据分布】



# LDA降维实战

用scikit-learn进行LDA降维

## 【PCA降维到二维】

```
from sklearn.decomposition import PCA
pca = PCA(n_components=2)
pca.fit(X)
print pca.explained_variance_ratio_
print pca.explained_variance_
X_new = pca.transform(X)
plt.scatter(X_new[:, 0], X_new[:, 1], marker='o', c=y)
plt.show()
```

PCA找到的两个主成分方差比和方差

[ 0.43377069	0.3716351 ]
[ 1.20962365	1.03635081]

样本特征和类别的信息关联几乎完全丢失!



# LDA降维实战

用scikit-learn进行LDA降维

## 【LDA降维到二维】

---


```
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
lda = LinearDiscriminantAnalysis(n_components=2)
lda.fit(X,y)
X_new = lda.transform(X)
plt.scatter(X_new[:, 0], X_new[:, 1],marker='o',c=y)
plt.show()
```

---


降维后样本特征和类别信息之间的关系得以保留。

# LDA降维实战

用scikit-learn进行LDA降维



(a) PCA降维结果



(b) LDA降维结果

# Thank You

AI300学院

